

THIẾT KẾ HỆ THỐNG

Server AI Phân loại & Định tuyến Văn bản đến

Giải pháp tự động hoá phân loại, trích xuất metadata và định tuyến văn bản đến cho văn phòng Sở, ứng dụng kiến trúc Orchestration – Harness – Agent Skills trên nền tảng mô hình AI mã nguồn mở tự triển khai nội bộ.

Phạm vi thí điểm	Sở Nông nghiệp và Môi trường (Gia Lai)
Loại tài liệu	Đề xuất thiết kế kỹ thuật (technical design)
Đầu vào hệ thống	Văn bản đến kèm file PDF đính kèm — không cần nhập tay
Đầu ra hệ thống	Đơn vị xử lý chính · Phối hợp xử lý · Lãnh đạo theo dõi · Hạn thực hiện
Nguyên tắc bảo mật	Mô hình AI tự host on-premise, không gọi API bên ngoài, không rời mạng nội bộ

TÓM TẮT ĐỀ XUẤT

1. Bài toán và mục tiêu

Văn phòng Sở hiện xử lý văn bản đến theo cách thủ công: cán bộ đọc văn bản, tự xác định đơn vị xử lý chính, đơn vị phối hợp, lãnh đạo theo dõi và hạn thực hiện, sau đó nhập liệu để chuyển văn bản đi. Đề xuất này xây dựng một server AI nội bộ nhận trực tiếp văn bản đến kèm file đính kèm (PDF) — không cần bất kỳ thao tác nhập liệu nào — và tự động trả về đầy đủ 4 trường thông tin cần thiết để chuyển văn bản đi.

Trường đầu ra	Ý nghĩa nghiệp vụ
Đơn vị xử lý chính	Người/đơn vị chịu trách nhiệm xử lý chính (có thể kèm lãnh đạo phụ trách)
Phối hợp xử lý	Người/đơn vị phối hợp xử lý
Lãnh đạo theo dõi	Lãnh đạo theo dõi, chỉ đạo việc xử lý
Hạn thực hiện	Thời hạn hoàn thành, trích từ nội dung văn bản (hoặc để trống nếu văn bản không nêu rõ)

Toàn bộ quy trình suy luận ra 4 trường trên đi qua ba bước: trích nội dung PDF → trích metadata nghiệp vụ (số hiệu, loại văn bản, cơ quan ban hành, người ký, ngày, trích yếu, hạn) → áp dụng bộ rule định tuyến riêng của từng Sở.

2. Vì sao chọn Rule Engine thay vì RAG

Đây là quyết định kiến trúc cốt lõi. Danh sách quy tắc phân công xử lý do lãnh đạo/quản trị viên Sở quy định là một tập hữu hạn, có cấu trúc rõ ràng (điều kiện → cơ quan nhận) — không phải bài toán tìm kiếm ngữ nghĩa trong kho tài liệu lớn. Vì vậy hệ thống tách bạch hai lớp xử lý:

- Rule engine thuần code (deterministic): áp dụng cho các điều kiện rõ ràng — chạy nhanh, chi phí thấp, dễ kiểm tra (audit) và luôn cho kết quả có thể dự đoán trước.
- Model AI suy luận (open-weight, tự host): chỉ xử lý phần "mờ" — metadata không theo mẫu cố định, phân loại mang tính ngữ nghĩa, hoặc trường hợp không rule nào khớp.
- Toàn bộ bộ rule của Sở được nạp thẳng vào ngữ cảnh (context) của model khi cần suy luận — không dùng retrieval/embedding — vì đây là tập luật nhỏ, tường minh.
- Với khối lượng dữ kiện ~600 văn bản/ngày, hệ thống tận dụng cơ chế prefix caching (vLLM/TGI) để giữ phần system prompt và rule set cố định trong bộ nhớ đệm, giảm chi phí suy luận lặp lại.

3. Nguyên tắc bảo mật dữ liệu

Văn bản đến của Sở có thể thuộc loại nhạy cảm hoặc mật, do đó dữ liệu không được phép rời khỏi mạng nội bộ. Mô hình AI mã nguồn mở (open-weight) được tự triển khai trên GPU đặt tại chỗ (on-premise), chạy hoàn toàn offline. Toàn bộ Harness điều phối, Rule Engine và máy chủ suy luận (inference server) đều nằm trên cùng hệ thống máy chủ tại đơn vị, không có kết nối gọi ra API mô hình AI bên ngoài.

KIẾN TRÚC HỆ THỐNG

4. Luồng xử lý tổng thể

Hệ thống được tổ chức theo mô hình Orchestration – Harness – Agent Skills, trong đó Harness đóng vai trò "nhạc trưởng" điều phối các bước xử lý, còn Rule Engine và các Agent Skills đảm nhiệm từng nghiệp vụ cụ thể. Sáu bước xử lý chính diễn ra tuần tự như sau:

Bước	Thành phần	Chức năng
Bước 1	API Layer	Nhận file đính kèm, kiểm tra hợp lệ, lưu tạm và khởi tạo mã công việc (job_id).
Bước 2	PDF Extractor	Trích xuất text từ file PDF (deterministic); OCR dự phòng cho bản scan.
Bước 3	Metadata Extractor	Trích số hiệu, loại văn bản, cơ quan ban hành, người ký, ngày, trích yếu, hạn thực hiện — ưu tiên regex, model chỉ xử lý phần không rõ mẫu.
Bước 4	Harness / Agent Loop	Điều phối gọi Tool và Skill theo nhu cầu: classify_document, rule_engine.apply, resolve_conflicts, explain_decision.
Bước 5	Rule Engine	Áp dụng bộ quy tắc định tuyến cứng (tường minh) của Sở tương ứng để suy ra 4 trường đầu ra.
Bước 6	Response Formatter	Trả kết quả JSON chuẩn hoá kèm độ tin cậy (confidence) và lý do (reason) để phục vụ kiểm tra.

5. Vai trò từng thành phần

Thành phần	Vai trò
PDF Extractor	Trích text từ PDF (pdfplumber/pypdf), OCR dự phòng cho bản scan
Metadata Extractor	Trích các trường nghiệp vụ và hạn thực hiện; deterministic trước, model sau
Harness	Vòng lặp điều phối, retry, giới hạn số bước, tự hạ cấp fallback T2 → T1 → T0
Rule Engine (code)	Áp dụng rule tường minh của Sở; tách khỏi model để đảm bảo nhanh, dễ audit, dự đoán được
Agent Skills	Đóng gói từng nghiệp vụ: trích metadata, phân loại văn bản, áp rule, xử lý xung đột, giải trình quyết định
Inference Server (vLLM/TGI)	Chạy mô hình open-weight tại chỗ, gọi qua API nội bộ, không cần Internet

6. Cơ chế fallback 3 bậc của Harness

Điểm mấu chốt đảm bảo độ tin cậy: Rule Engine luôn chạy độc lập, mô hình AI chỉ hỗ trợ phần việc mà rule chưa xử lý được. Nếu mô hình gặp sự cố, hệ thống tự động hạ cấp qua 3 bậc mà kết quả vẫn hợp lệ:

Bậc	Cách gọi model	Áp dụng khi
T2 — Tool-calling	Model tự gọi Tool (trích metadata, áp rule...) theo vòng lặp	Model hỗ trợ tốt function-calling
T1 — Prompt-only	Gộp toàn bộ văn bản và bộ rule vào 1 prompt, model trả về 1 JSON	Model không hỗ trợ tool-calling
T0 — Không dùng model	Chỉ chạy trích xuất + rule engine deterministic; phần chưa rõ được đánh dấu chờ người duyệt	Model lỗi, timeout hoặc parse hỏng

Kết quả trả về luôn kèm cờ degraded để phục vụ theo dõi và kiểm tra chất lượng.

DỮ LIỆU VÀO / RA

7. Đầu vào và đầu ra hệ thống

Điểm gọi POST /classify chỉ nhận duy nhất file đính kèm (thường là PDF) — không có payload JSON do người dùng nhập tay. Có thêm một trường văn bản tùy chọn phục vụ kiểm thử khi chưa có file thật.

Ví dụ kết quả trả về (rút gọn):

```
{
  "job_id": "...",
  "don_vi_xu_ly_chinh": ["Chi cục Thủy sản"],
  "phoi_hop_xu_ly": ["Giám đốc Cao Thanh Thương"],
  "lanh_dao_theo_doi": ["Giám đốc Cao Thanh Thương"],
  "han_thuc_hien": "2026-08-27",
  "confidence": 0.95,
  "reason": "Khớp rule V.9 — thủy lợi (bình thường)",
  "needs_review": false,
  "degraded": false,
  "tier": "T0"
}
```

8. Quy tắc xác định hạn thực hiện

Trường "Hạn thực hiện" được trích từ nội dung văn bản theo thứ tự ưu tiên:

- Ngày cụ thể được nêu rõ trong văn bản: dạng "trước ngày...", "hạn... ngày DD/MM/YYYY", "chậm nhất ngày...".
- Dấu hiệu khẩn cấp trong văn bản ("khẩn", "hoả tốc", "thượng khẩn") → gán giá trị "hoả tốc".
- Không xác định được hạn → để trống và gán cờ nhẹ để người duyệt tự bổ sung.

9. Cơ chế kiểm tra và con người xác nhận (Explainability & Human review)

Mỗi kết quả trả về đều kèm một chỉ số confidence (độ tin cậy), phản ánh việc kết quả đến từ rule khớp rõ ràng hay từ suy luận của model. Khi độ tin cậy thấp, nhiều rule mâu thuẫn nhau, hoặc metadata trích được không rõ ràng, hệ thống sẽ tự động gán cờ needs_review để cán bộ văn phòng xác nhận lại trước khi ban hành. Toàn bộ log — rule nào khớp, model giải thích ra sao, metadata đã trích — đều được lưu lại phục vụ kiểm tra (audit) và tinh chỉnh bộ rule về sau.

KẾ HOẠCH TRIỂN KHAI

10. Công nghệ sử dụng

Hạng mục	Công nghệ đề xuất
API	FastAPI (Python)
Trích xuất PDF	pdfplumber / pypdf (văn bản dạng text); Tesseract OCR offline cho bản scan
Trích xuất metadata	Regex thuần (deterministic) kết hợp model dự phòng cho phần chưa rõ mẫu
Lưu trữ rule	YAML/JSON riêng từng Sở; giai đoạn sau chuyển sang SQLite/Postgres kèm giao diện quản trị
Điều phối (Orchestration)	Harness tự xây dựng, gọi model qua API tương thích OpenAI do vLLM/TGI cung cấp
Mô hình AI	Open-weight tự host (Qwen2.5/Qwen3, Llama...) — sẽ benchmark lại tại thời điểm triển khai
Nhật ký kiểm tra (Audit)	SQLite cho giai đoạn thử nghiệm → Postgres khi đưa vào sản xuất

11. Lộ trình thực hiện theo 3 giai đoạn

Giai đoạn 1	Demo local — thí điểm tại Sở NN&MT;
- Xây dựng PDF extractor trích text từ file đính kèm. - Xây dựng metadata extractor: số hiệu, loại, cơ quan, ngày, trích yếu, hạn (deterministic). - Xây dựng rule engine: rulebase riêng Sở NN&MT;, cho ra đủ 4 trường đầu ra. - Tích hợp Harness và mô hình AI nội bộ cho phần metadata/phân loại chưa rõ; cơ chế fallback T2→T1→T0. - Xây dựng Agent Skills hướng dẫn từng bước suy luận. - Kiểm thử đầu-cuối (end-to-end) với một số văn bản mẫu thật. - Xây dựng nhật ký kiểm tra (audit log): lưu đầu vào, metadata trích, rule khớp, kết quả.	
Giai đoạn 2	Triển khai server GPU tại đơn vị, hoạt động 24/24

- Đóng gói Docker + docker-compose, quản lý thông tin cấu hình qua file .env.
- Thiết lập reverse proxy (Nginx) trong mạng nội bộ, không mở ra Internet.
- Thiết lập giám sát uptime, sao lưu (backup) bộ rule, tự khởi động lại khi có sự cố.
- Cài đặt vLLM/TGI trên GPU với mô hình đã benchmark; Harness gọi qua mạng nội bộ (LAN).

Giai đoạn 3

Mở rộng áp dụng cho nhiều Sở khác

- Tách cấu trúc rulebase theo mô hình "một Sở = một bộ rule + danh bạ nhân sự riêng", bổ sung tham số chọn Sở.
- Xây dựng giao diện quản trị (Admin UI) để quản lý rule.
- Chuẩn hoá danh bạ nhân sự dùng chung giữa các Sở.

KIẾN NGHỊ & ĐIỂM CẦN QUYẾT ĐỊNH

12. Các điểm đã xác nhận trong thiết kế

- ✓ Đầu vào: chỉ gồm văn bản và file đính kèm (PDF), không cần payload JSON nhập tay.
- ✓ Đầu ra: đủ 4 trường — Đơn vị xử lý chính, Phối hợp xử lý, Lãnh đạo theo dõi, Hạn thực hiện.
- ✓ Knowledge base: rulebase riêng cho từng Sở; triển khai thí điểm trước tại Sở NN&MT.;
- ✓ Hạn thực hiện: trích từ nội dung văn bản; văn bản khẩn → "hoà tốc"; không xác định được → để trống.
- ✓ Định dạng dữ liệu đầu ra: chuẩn hoá khoá tên trường để hệ thống nhận có thể xử lý tự động.

13. Điểm còn cần xác nhận từ lãnh đạo

- ? OCR cho bản scan: cần triển khai ngay từ giai đoạn đầu hay chưa — do phần lớn văn bản đầu vào dự kiến là dạng có text sẵn (không phải bản scan hình ảnh)?

14. Bước tiếp theo đề xuất

- Hoàn thiện lại bộ khung mã nguồn (code skeleton) theo kiến trúc mới đã thống nhất.
- Thu thập 20–30 văn bản mẫu thật (PDF) để đánh giá độ chính xác của bước trích metadata và định tuyến.
- Benchmark các mô hình AI open-weight ứng viên trước khi cam kết đầu tư hạ tầng GPU.

Tài liệu này tổng hợp từ bản thiết kế kỹ thuật nội bộ, phục vụ mục đích trình bày và xin ý kiến chỉ đạo của lãnh đạo Sở trước khi triển khai giai đoạn 1.