

KẾ HOẠCH THỰC HIỆN — AI Document Router

Sở Nông nghiệp và Môi trường tỉnh Gia Lai

Phiên bản: v1.0 — Trạng thái: Giai đoạn demo local.

1. Mục tiêu

Xây dựng server AI **định tuyến văn bản đến**: nhận văn bản + file đính kèm (PDF), tự trích thông tin từ nội dung, áp dụng rulebase của Sở, trả về kết quả để chuyển văn bản đi gồm 4 trường:

- Đơn vị xử lý chính
- Phối hợp xử lý
- Lãnh đạo theo dõi
- Hạn thực hiện

Không dùng RAG; rulebase quản lý tường minh riêng từng Sở; model open-weight tự host (offline).

2. Phạm vi giai đoạn đầu

- Triển khai cho **Sở NN&MT** trước.
- Đầu vào: PDF text-based (bản scan/OCR xử lý sau).
- Chạy local (mock inference server) → sau nâng lên GPU on-prem.

3. Các giai đoạn

Giai đoạn	Nội dung	Kết quả
GĐ1 — Demo local	Skeleton API, PDF extractor, metadata extractor, rule engine, harness + mock model, audit log, test	Chạy được end-to-end trên máy cá nhân
GĐ2 — Triển khai GPU	Docker, Nginx nội bộ, vLLM/TGI + model benchmark, giám sát, backup	Chạy 24/24 tại công ty, offline
GĐ3 — Mở rộng đa Sở	Tách rulebase đa Sở, admin UI, chuẩn hóa danh bạ	Dùng cho nhiều Sở

4. Công việc chi tiết — Giai đoạn 1 (demo local)

#	Công việc	Deliverable	Trạng thái
1	Viết lại bản thiết kế (bỏ payload JSON, output 4 trường)	thiet-ke-ai-document-router.md	✅ Xong
2	PDF extractor (text + hook OCR)	app/pdf/extractor.py	✅ Xong
3	Metadata extractor (số hiệu, loại, cơ quan, ngày, trích yếu, hạn)	app/extract/metadata.py	✅ Xong
4	Rule engine deterministic + rules.yaml SoNNMT	app/rules/engine.py, app/rules/rules.yaml	✅ Xong
5	Harness fallback T2→T1→T0 + mock/HTTP inference	app/orchestrator/harness.py	✅ Xong
6	API POST /classify (chỉ file đính kèm) + schema 4 trường	app/api/routes.py, app/models/schema.py	✅ Xong
7	Audit log SQLite	app/storage/audit.py	✅ Xong
8	Unit test + smoke test API	tests/ (30 test)	✅ Xong
9	Thu thập 20–30 văn bản mẫu thật, đánh giá độ chính xác	bộ test + báo cáo eval	⌚ Chờ dữ liệu
10	Benchmark model (Qwen2.5/3, Llama...)	báo cáo chọn model	⌚ Chờ GPU

5. Công việc — Giai đoạn 2 (triển khai GPU)

#	Công việc
1	Docker + docker-compose, secret qua .env
2	Reverse proxy Nginx trong mạng nội bộ (không expose Internet)
3	Cài vLLM/TGI trên GPU, load model đã benchmark
4	Giám sát uptime, backup rulebase, restart tự động

6. Công việc — Giai đoạn 3 (mở rộng đa Sở)

#	Công việc
1	Tách rulebase thành "một Sở = một bộ rule + danh bạ"
2	Thêm tham số/endpoint chọn Sở
3	Admin UI quản lý rule; chuẩn hóa danh bạ nhân sự

7. Rủi ro & biện pháp

Rủi ro	Mức	Biện pháp
Open-weight model yếu ở rule chòng chéo/tiếng Việt	Cao	Benchmark trước khi mua GPU; fine-tune nhẹ; tăng tỷ lệ flag người duyệt
Trích metadata từ PDF kém chính xác (cơ quan ban hành, người ký)	Trung bình	Deterministic regex + model fallback; eval trên văn bản thật
Dữ liệu rulebase chưa sạch (địa danh, ký hiệu, nhân sự)	Trung bình	Rà soát/chuẩn hóa trước khi vận hành
Văn bản mật rò rỉ	Cao	Offline hoàn toàn, VPC nội bộ, không Internet

8. Tiêu chí hoàn thành (Giai đoạn 1)

- [x] `POST /classify` nhận file PDF, không cần payload JSON.
- [x] Trả đúng 4 trường kết quả.
- [x] Rule engine khớp đúng thứ tự ưu tiên của rulebase SoNNMT.
- [x] Test chạy xanh (30 test).
- [] Độ chính xác routing $\geq 90\%$ trên bộ 30 văn bản mẫu thật (chờ dữ liệu).

9. Cột mốc

Mốc	Thời gian dự kiến
Hoàn thiện skeleton + test (đã xong)	Phiên này
Bộ eval 30 văn bản thật	Khi có dữ liệu
Benchmark model	~1 tuần sau khi có GPU
Triển khai GPU 24/24	Sau khi chọn model