

KẾ HOẠCH THỰC HIỆN — AI Document Router

Sở Nông nghiệp và Môi trường tỉnh Gia Lai

Phiên bản: v1.1 — Trạng thái: Giai đoạn demo local.

1. Mục tiêu

Xây dựng server AI **định tuyến văn bản đến**: nhận văn bản + file đính kèm (PDF), tự trích thông tin từ nội dung, áp dụng rulebase của Sở, trả về kết quả để chuyển văn bản đi gồm 4 trường:

- Đơn vị xử lý chính
- Phối hợp xử lý
- Lãnh đạo theo dõi
- Hạn thực hiện

Không dùng RAG; rulebase quản lý tường minh riêng từng Sở; model open-weight tự host (offline).

2. Phạm vi giai đoạn đầu

- Triển khai cho **Sở NN&MT** trước.
- Đầu vào: PDF — cần xác minh SỐM tỷ lệ scan vs text gốc (bước 0) để chốt OCR có bắt buộc ở đầu hay không.
- Chạy local (mock inference server) → sau nâng lên GPU on-prem.

3. Các giai đoạn

Giai đoạn	Nội dung	Kết quả
GĐ1 — Demo local	Skeleton API, PDF extractor, metadata extractor, rule engine, harness + mock model, audit log, test	Chạy được end-to-end trên máy cá nhân
GĐ2 — Triển khai GPU	Docker, Nginx nội bộ, vLLM/TGI + model benchmark, giám sát, backup	Chạy 24/24 tại công ty, offline
GĐ3 — Mở rộng đa Sở	Tách rulebase đa Sở, admin UI, chuẩn hóa danh bạ	Dùng cho nhiều Sở

4. Công việc chi tiết — Giai đoạn 1 (demo local)

#	Công việc	Deliverable	Trạng thái
0	Thu thập 20–30 văn bản mẫu thật + xác minh OCR (làm TRƯỚC)	bộ mẫu + kết luận OCR	⌚ Chờ dữ liệu
1	Viết lại bản thiết kế (bỏ payload JSON, output 4 trường)	thiet-ke-ai-document-router.md	✅ Xong
2	PDF extractor (text + hook OCR)	app/pdf/extractor.py	✅ Xong
3	Metadata extractor (số hiệu, loại, cơ quan, ngày, trích yếu, hạn)	app/extract/metadata.py	✅ Xong
4	Rule engine deterministic + rules.yaml SoNNMT	app/rules/engine.py, app/rules/rules.yaml	✅ Xong
5	Harness fallback T2→T1→T0 + mock/HTTP inference	app/orchestrator/harness.py	✅ Xong
6	API POST /classify (chỉ file đính kèm) + schema 4 trường	app/api/routes.py, app/models/schema.py	✅ Xong
7	Audit log SQLite	app/storage/audit.py	✅ Xong
8	Unit test + smoke test API	tests/ (30 test)	✅ Xong
8a	Refactor rule sang chức danh + bảng nhân sự riêng	rules.yaml + bảng nhân sự	🏆 Đề xuất
8b	Validate/sanitize output model (chống prompt injection)	guard trong harness.py	🏆 Đề xuất
9	Thu thập 20–30 văn bản mẫu thật, đánh giá độ chính xác	bộ test + báo cáo eval	⌚ Chờ dữ liệu
10	Benchmark model (Qwen2.5/3, Llama...) — SONG SONG từ bước 4	báo cáo chọn model	⌚ Chờ GPU

5. Công việc — Giai đoạn 2 (triển khai GPU)

#	Công việc
1	Docker + docker-compose, secret qua .env
2	Reverse proxy Nginx trong mạng nội bộ (không expose Internet)
3	Cài vLLM/TGI trên GPU, load model đã benchmark
4	Giám sát uptime, backup rulebase, restart tự động

6. Công việc — Giai đoạn 3 (mở rộng đa Sở)

#	Công việc
1	Tách rulebase thành "một Sở = một bộ rule + danh bạ"
2	Thêm tham số/endpoint chọn Sở
3	Admin UI quản lý rule; chuẩn hóa danh bạ nhân sự

7. Rủi ro & biện pháp

Rủi ro	Mức	Biện pháp
Open-weight model yếu ở rule chòng chéo/tiếng Việt	Cao	Benchmark trước khi mua GPU; fine-tune nhẹ; tăng tỷ lệ flag người duyệt

Rủi ro	Mức	Biện pháp
Trích metadata từ PDF kém chính xác (cơ quan ban hành, người ký)	Trung bình	Deterministic regex + model fallback; eval trên văn bản thật
Dữ liệu rulebase chưa sạch (địa danh, ký hiệu, nhân sự)	Trung bình	Rà soát/chuẩn hóa trước khi vận hành
Văn bản mật rò rỉ	Cao	Offline hoàn toàn, VPC nội bộ, không Internet
Văn bản scan phổ biến, text extract kém	Cao	Xác minh OCR sớm (bước 0); Tesseract + model vision fallback
Rule theo tên người lỗi thời khi luân chuyển	Trung bình	Rule theo chức danh + bảng nhân sự cập nhật riêng
Prompt injection từ nội dung văn bản	Thấp–Trung bình	Rule engine deterministic + validate/sanitize output model
Trách nhiệm khi AI định tuyến sai	Cao	Quy trình sign-off do lãnh đạo chốt

8. Tiêu chí hoàn thành (Giai đoạn 1)

- [x] `POST /classify` nhận file PDF, không cần payload JSON.
- [x] Trả đúng 4 trường kết quả.
- [x] Rule engine khớp đúng thứ tự ưu tiên của rulebase SoNNMT.
- [x] Test chạy xanh (30 test).
- [] Độ chính xác trích metadata $\geq 95\%$ (bộ 30 văn bản mẫu thật).
- [] Độ chính xác routing $\geq 90\%$ (bộ 30 văn bản mẫu thật).
- [] Tỷ lệ `needs_review` $\leq 20\%$ (case "mờ").

9. Cột mốc

Mốc	Thời gian dự kiến
Hoàn thiện skeleton + test (đã xong)	Phiên này
Xác minh OCR + bộ 30 văn bản mẫu thật	Bước 0 (làm trước)
Bộ eval 30 văn bản thật	Khi có dữ liệu
Benchmark model	~1 tuần sau khi có GPU
Triển khai GPU 24/24	Sau khi chọn model