

KẾ HOẠCH THỰC HIỆN — AI Document Router

Sở Nông nghiệp và Môi trường tỉnh Gia Lai

Phiên bản: v1.1 — Trạng thái: Giai đoạn demo local.

1. Mục tiêu

Xây dựng server AI **định tuyến văn bản đến**: nhận văn bản + file đính kèm (PDF), tự trích thông tin từ nội dung, áp dụng rulebase của Sở, trả về kết quả để chuyển văn bản đi gồm 4 trường:

- Đơn vị xử lý chính
- Phối hợp xử lý
- Lãnh đạo theo dõi
- Hạn thực hiện

Không dùng RAG; rulebase quản lý tường minh riêng từng Sở; model open-weight tự host (offline).

2. Phạm vi giai đoạn đầu

- Triển khai cho **Sở NN&MT** trước.
- Đầu vào: PDF — cần xác minh SỐM tỷ lệ scan vs text gốc (bước 0) để chốt OCR có bắt buộc ở đầu hay không.
- Chạy local (mock inference server) → sau nâng lên GPU on-prem.

2a. Hạ tầng phần cứng & mô hình OCR (quyết định triển khai)

Phần cứng

- GPU**: NVIDIA GeForce **RTX 4090 — 24 GB GDDR6X VRAM**, băng thông ~1 008 GB/s. Đủ chạy mô hình VLM 7B ở FP16 (weights ~14 GB) hoặc bản lượng tử AWQ/GPTQ 4-bit (~5 GB weights).
- Card consumer: không ECC, không NVLink, single-GPU → phù hợp phục vụ **một model thường trú tại một thời điểm** (hoặc OCR VLM + model định tuyến nhỏ/lượng tử).

Mô hình OCR

- OCR bản scan: Qwen2.5-VL-7B-Instruct** (vision-language 7B, context 125K), phục vụ qua **vLLM** (API tương thích OpenAI, offline on-prem).
- Vai trò: trích toàn văn bản từ ảnh scan, chất lượng cao hơn Tesseract (đọc bảng, chữ ký, tiếng Việt tốt hơn).
- Tham khảo cộng đồng (cần benchmark lại khi triển khai): trên RTX 4090 bản tối ưu ghi nhận ~18.2 GB VRAM, độ trễ <1.8 s/ảnh.

Ngân sách VRAM & xung đột 2 model

- Chạy đồng thời **Qwen2.5-VL-7B (OCR)** và **model định tuyến (T1/T2)** trên **cùng 1 GPU 24 GB** sẽ cạnh tranh VRAM. Khuyến nghị:
 - Ưu tiên OCR VLM thường trú — phần lớn văn bản đi qua rule engine **T0 deterministic**, không cần model định tuyến.
 - Model định tuyến chỉ tải khi cần (time-share) hoặc dùng bản nhỏ/lượng tử (Qwen2.5-7B-Instruct AWQ 4-bit), giới hạn batch + context.
 - Khi lưu lượng tăng → bổ sung GPU thứ hai để tách OCR vs reasoning.

Cấu hình vLLM gợi ý (server OCR, cổng 8001)

```
vllm serve Qwen/Qwen2.5-VL-7B-Instruct \
--dtype bfloat16 \
--max-model-len 16384 \
--gpu-memory-utilization 0.90 \
--port 8001
```

Client kết nối qua `OCR_SERVER_URL=http://127.0.0.1:8001` (xem `.env.example`).

3. Các giai đoạn

Giai đoạn	Nội dung	Kết quả
GĐ1 — Demo local	Skeleton API, PDF extractor, metadata extractor, rule engine, harness + mock model, audit log, test	Chạy được end-to-end trên máy cá nhân
GĐ2 — Triển khai GPU	Docker, Nginx nội bộ, vLLM serve Qwen2.5-VL-7B (OCR) + model định tuyến trên RTX 4090 , giám sát, backup	Chạy 24/24 tại công ty, offline
GĐ3 — Mở rộng đa Sở	Tách rulebase đa Sở, admin UI, chuẩn hóa danh bạ	Dùng cho nhiều Sở

4. Công việc chi tiết — Giai đoạn 1 (demo local)

#	Công việc	Deliverable	Trạng thái
0	Thu thập 20–30 văn bản mẫu thật + xác minh OCR (làm TRƯỚC)	bộ mẫu + kết luận OCR (text vs scan)	⌚ Chờ dữ liệu
1	Viết lại bản thiết kế (bỏ payload JSON, output 4 trường)	thiet-ke-ai-document-router.md	✅ Xong
2	PDF extractor (text + OCR Qwen2.5-VL-7B + Tesseract fallback)	app/pdf/extractor.py	✅ Xong
3	Metadata extractor (số hiệu, loại, cơ quan, ngày, trích yếu, hạn)	app/extract/metadata.py	✅ Xong
4	Rule engine deterministic + <code>rules.yaml</code> SoNNMT	app/rules/engine.py, app/rules/rules.yaml	✅ Xong
5	Harness fallback T2→T1→T0 + mock/HTTP inference	app/orchestrator/harness.py	✅ Xong
6	API <code>POST /classify</code> (chỉ file đính kèm) + schema 4 trường	app/api/routes.py, app/models/schema.py	✅ Xong
7	Audit log SQLite	app/storage/audit.py	✅ Xong
8	Unit test + smoke test API	tests/ (30 test)	✅ Xong
8a	Refactor rule sang chức danh + bảng nhân sự riêng	rules.yaml + bảng nhân sự	⌚ Đề xuất

#	Công việc	Deliverable	Trạng thái
8b	Validate/sanitize output model (chống prompt injection)	guard trong <code>harness.py</code>	Đề xuất
9	Thu thập 20–30 văn bản mẫu thật, đánh giá độ chính xác	bộ test + báo cáo eval	Chờ dữ liệu
10	Benchmark model định tuyến (Qwen2.5/3, Llama...) + Qwen2.5-VL-7B OCR — SONG SONG từ bước 4	báo cáo chọn model	Chờ GPU

5. Công việc — Giai đoạn 2 (triển khai GPU)

#	Công việc
1	Docker + docker-compose, secret qua <code>.env</code>
2	Reverse proxy Nginx trong mạng nội bộ (không expose Internet)
3	Cài vLLM trên RTX 4090: serve Qwen2.5-VL-7B-Instruct (OCR, cổng 8001)
4	Serve model định tuyến (bậc T1/T2) — tách tiến trình / time-share với OCR VLM
5	Giám sát uptime, backup rulebase, restart tự động

6. Công việc — Giai đoạn 3 (mở rộng đa Sở)

#	Công việc
1	Tách rulebase thành "một Sở = một bộ rule + danh bạ"
2	Thêm tham số/endpoint chọn Sở
3	Admin UI quản lý rule; chuẩn hóa danh bạ nhân sự

7. Rủi ro & biện pháp

Rủi ro	Mức	Biện pháp
Open-weight model yếu ở rule chòng chéo/tiếng Việt	Cao	Benchmark trước khi mua GPU; fine-tune nhẹ; tăng tỷ lệ flag người duyệt
Trích metadata từ PDF kém chính xác (cơ quan ban hành, người ký)	Trung bình	Deterministic regex + model fallback; eval trên văn bản thật
Dữ liệu rulebase chưa sạch (địa danh, ký hiệu, nhân sự)	Trung bình	Rà soát/chuẩn hóa trước khi vận hành
Văn bản mật rò rỉ	Cao	Offline hoàn toàn, VPC nội bộ, không Internet
Văn bản scan phổ biến, text extract kém	Cao	Xác minh OCR sớm (bước 0); Qwen2.5-VL-7B (vLLM) + Tesseract fallback
Cạnh tranh VRAM giữa OCR VLM và model định tuyến trên 1× RTX 4090	Cao	OCR VLM thường trú; model định tuyến time-share/lượng tử; thêm GPU khi tải cao
Rule theo tên người lỗi thời khi luân chuyển	Trung bình	Rule theo chức danh + bảng nhân sự cập nhật riêng
Prompt injection từ nội dung văn bản	Thấp–Trung bình	Rule engine deterministic + validate/sanitize output model
Trách nhiệm khi AI định tuyến sai	Cao	Quy trình sign-off do lãnh đạo chốt

8. Tiêu chí hoàn thành (Giai đoạn 1)

- ☒ POST `/classify` nhận file PDF, không cần payload JSON.
- ☒ Trả đúng 4 trường kết quả.
- ☒ Rule engine khớp đúng thứ tự ưu tiên của rulebase SoNNMT.
- ☒ Test chạy xanh (30 test).
- ☐ Độ chính xác trích metadata $\geq 95\%$ (bộ 30 văn bản mẫu thật).
- ☐ Độ chính xác routing $\geq 90\%$ (bộ 30 văn bản mẫu thật).
- ☐ Tỷ lệ `needs_review` $\leq 20\%$ (case "mờ").

9. Cột mốc

Mốc	Thời gian dự kiến
Hoàn thiện skeleton + test (đã xong)	Phiên này
Xác minh OCR + bộ 30 văn bản mẫu thật	Bước 0 (làm trước)
Bộ eval 30 văn bản thật	Khi có dữ liệu
Benchmark model	~1 tuần sau khi có GPU
Triển khai GPU 24/24	Sau khi chọn model
Serve Qwen2.5-VL-7B OCR trên RTX 4090	Khi có GPU